

UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE AUTOMAÇÃO E SISTEMAS



**UNIVERSIDADE FEDERAL
DE SANTA CATARINA**

EXERCÍCIO 1: ALGORITMO GENÉTICO

INTELIGÊNCIA ARTIFICIAL

Juliano Ricardo da Silva
Prof. Dr. Eric Antonelo

FLORIANÓPOLIS - SC

FEVEREIRO DE 2022

Conteúdo

1	Algoritmo Genético	3
2	Análise	11
2.a	Aptidão média	11
2.b	Aptidão em função do cromossomo	14

1 Algoritmo Genético

O algoritmo genético programado pode ser conferido abaixo:

```
1 #Juliano Ricardo da Silva
2 #Nao usei o template fornecido
3
4 #Algoritmo genetico
5
6 L = 4 * 8 #size of chromossome in bits
7
8 import struct
9 import random
10 import math
11 import matplotlib.pyplot as plot
12 import numpy as np
13 import os
14
15 def floatToBits(f):
16     s = struct.pack('>f', f)
17     return struct.unpack('>L', s)[0]
18
19 def bitsToFloat(b):
20     s = struct.pack('>L', b)
21     return struct.unpack('>f', s)[0]
22
23 #exemplo 1.23 -> '0010111100'
24
25 def get_bits(x):
26     x = floatToBits(x)
27     N = 4 * 8
28     bits = ''
29     for bit in range(N):
30         b = x & (2**bit)
31         bits += '1' if b > 0 else '0'
32     return bits
33
34 #exemplo '00010111100' -> 1.23
35
36 def get_float(bits):
37     x = 0
38     assert(len(bits) == L)
39     for i, bit in enumerate(bits):
40         bit = int(bit) #0 or 1
41         x += bit * (2**i)
42     return bitsToFloat(x)
```

```

43
44 #size of population
45 global n
46
47 #gets population size by user input
48 def pop_len():
49     p = int(input("digit the size of population: "))
50     if (p<=2):
51         print("minimum value is 4")
52         p = 4
53         return p
54     elif(p%2 != 0):
55         print("odd number")
56         p = p - 1
57         print("changed to even")
58         return p
59     else:
60         return p
61
62 #gets the generation number by user input
63 def gen_len():
64     p = int(input("digit the number of generations: "))
65     return p
66
67 #generates a random list of people (chromossomes)
68 def population():
69     for i in range(g):
70         p = random.SystemRandom().uniform(0, math.pi)
71         person = get_bits(p)
72         people.append(person)
73
74 #fitness calculation for each chromossome
75 def calc_fitness(p):
76     for t in range(len(p)):
77         p[t] = get_float(p[t])
78         fitness = p[t] + abs(math.sin(32*p[t]))
79         #if fitness doesnt respect the limits [0,pi), their fitness
            is equal zero to avoid their spread
80         if fitness < 0 or fitness > math.pi:
81             fitness = 0
82             fitnessList.append(fitness)
83         else:
84             fitnessList.append(fitness)
85     return fitnessList
86

```

```

87
88 #selects two chromossomes to posterior crossover
89 def roulette_selection(listpop, fit):
90     store = []
91     st = []
92     while not(len(store) == 2):
93         store.extend((random.choices(listpop, fit, k=1)))
94         for i in store:
95             st.append(get_bits(i))
96     #while there are two chromossomes
97     while st[-1] == st[-2]:
98         print("*****TWO EQUAL CHROMOSSOMES, MAKE NEW
99             SELECTION*****")
100        st = []
101        store.extend((random.choices(listpop, fit, k=1))) #repeat
102        selection in population
103        for i in store: st.append(get_bits(i))
104    return st[-2:]
105
106 def roulette(lst, ft):
107     store2 = []
108     c = 0
109     while not(len(store2) == 2):
110         lst=lst[-n:]
111         ft = ft[-n:]
112         store2.extend((random.choices(lst, ft, k=1)))
113     while (store2[-1] == store2[-2]):
114         print("*****TWO EQUALS CHROMOSSOMES, MAKE NEW
115             SELECTION*****")
116         store2[-1] = lst[0+c]
117         store2[-2] = lst[-1+c]
118         c+=1
119         print("NOW, THE COUPLE IS: ", store2)
120     return store2
121
122 #single point crossover
123 def crossover():
124     pc = random.randint(1,10)/10
125     if pc > 1: pc = 1
126     if pc < 0.1: pc = 0.1
127     if 0.1 <= pc <= 0.7:
128         print('crossover resulted in: \n')
129         d1 = dad[0:16]+mom[16:32]
130         d2 = mom[0:16]+dad[16:32]
131         print(d1, d2)

```

```

129
130     else:
131         print("identical copy \n")
132         d1 = dad[:]
133         d2 = mom[:]
134         descendants.append(d1)
135         descendants.append(d2)
136         return descendants
137
138 #mutation
139 def mutation():
140     pm = random.randint(1,1000)
141     if pm > 1000: pm = 1000
142     if pm < 1: pm = 1
143     if pm == 1:
144         md = []
145         sd = descendants[random.randint(0,1)]
146         if sd == descendants[-2]:
147             new_population.append(descendants[-1])
148         else:
149             new_population.append(descendants[-2])
150
151         ap = random.randint(0,32)
152         if (0 >= ap or ap >= 32): ap = 0
153         if sd[ap] == '0':
154             m = '1'
155         else:
156             m = '0'
157         md = sd[:ap] + m + sd[ap+1:]
158         print("selected descendant:",sd)
159         print("position:",ap)
160         print("the mutated chromossome is: \n",md)
161         new_population.append(md)
162         return new_population
163     else:
164         new_population.append(descendants[-2])
165         new_population.append(descendants[-1])
166         print("doesn't occurred a mutation")
167     return new_population
168
169 #fitness calculation for each chromossome after their evolution
170 def calc_avg_fitness(newfit):
171     avg_fit = sum(newfit)/g
172     return avg_fit
173

```

```

174 chrome = []
175 n = pop_len()
176 g = n
177 iterations = 0
178 new_pop = []
179 iters = gen_len()
180 people = []
181 new_chrome = []
182 chromossome = []
183 avg = []
184 firstgen = []
185 secgen = []
186 lastgen = []
187
188 while iterations != iters:
189     iterations+=1
190
191     #first generation to be created and selected until chromossomes_evolved
    = size of population
192     if(iterations==1 and people ==[]):
193         print("*****GERACAO NRO *****", iterations)
194         print("The population number is ", g)
195         population() #population
196         print("\n*****The population of chromossomes in bit chain: *****
            \n",people)
197         fitnessList = []
198         calc_fitness(people) #calculates the fitness for each
            chromossome
199         print("\n*****List of fitness: *****\n ",fitnessList)
200         avg.append(calc_avg_fitness(fitnessList)) #calculates the
            average fitness of the first population
201         print("\n*****AVERAGE FITNESS: ",avg)
202         while(len(chrome) != g):
203             couple = []
204             couple = roulette_selection(people,fitnessList) #selects a
                couple of chromossomes
205             print("\n*****The selected couple is: *****\n", couple)
206             dad = couple[0]
207             mom = couple[1]
208             descendants = []
209             crossover() #chromossomes crossover (or not) to generate
                descendants
210             new_population = []
211             mutation() #chromossomes mutation (or not) to generate
                descendants

```

```

212         for i in new_population:
213             chrome.append(i)
214             print("\n*****New chromossomes: *****\n",chrome) #the new
                population of chromossomes
215     x = []
216     new_gen = chrome
217     print("\n*****population list to create next generation is*****\n", new_gen)
218     for i in new_gen:
219         firstgen.append(get_float(i))
220
221     #if the first generation was created, the new one will be generated
        based on the fitnesslist from previous generation
222     if(people != []):
223         for i in new_gen:
224             new_pop.append(i)
225             chromossome = []
226             x = []
227             new_population = []
228             fitnessList = []
229             descendants = []
230             new_chrome = []
231
232     #is the first generation already created? therefore, repeats the natural
        selection process for each next generation
233     if(iterations >= 2 and len(avg) != iters):
234         print("*****")
235         print("*****GENERATION NUMBER: ", iterations)
236         print("*****")
237         print("\n New population is: \n", new_pop[-n:])
238         calc_fitness(new_pop[-n:])
239         print("\n New fitness list is: \n", fitnessList[-n:])
240         avg.append(calc_avg_fitness(fitnessList[-n:]))
241         #while number of chromossomes is different of population size,
            repeats the process
242         while(len(chromossome) != g):
243             x = []
244             x = roulette(new_pop, fitnessList)#selects two
                chromossomes to crossover
245             print("\n*****Couple selected: *****\n", x[-n:])
246             dad = x[0]
247             mom = x[1]
248             crossover()
249             mutation()
250

```



```

251         for i in [new_population[-2],new_population[-1]]:
252             new_chrome.append(i)
253         chromossome.extend([new_chrome[-2],new_chrome[-1]])
254         print("\n*****New chromossomes*****\n", chromossome)
255
256
257         new_gen = chromossome
258         print("\n*****population list to create next generation is*****\n", new_gen)
259
260         if(iterations == 10):
261             for j in chromossome:
262                 secgen.append(get_float(j))
263         if(iterations == 600):
264             for k in chromossome:
265                 lastgen.append(get_float(i))
266
267         print("done!")
268         print("population length: ", len(chrome))
269         print("AVG FITNESS LIST: ", avg)
270
271         print("FIRST GEN:", firstgen)
272         print("SECOND GEN:", secgen)
273         print("LAST GEN:", lastgen)
274
275         #plot avg fitness list
276         xx_value = list(range(0, iters))
277         yy_value = [f for f in avg]
278         plot.plot(xx_value, yy_value, label = "Average fitness list")
279         plot.legend()
280         plot.show()
281
282         yval = [f for f in firstgen] #1st generation chromossomes
283         yval2 = [g for g in secgen] #10th generation chromossomes
284
285         fg = []
286         sg = []
287         lg = []
288
289         #calculates the fitness from the generations of chromossomes selected
290         def fit_gen(g,h):
291             for t in g:
292                 fitness = t + abs(math.sin(32*t))
293                 h.append(fitness)
294             return h

```

```


295 fit_gen(firstgen , fg)
296 fit_gen(secgen , sg)
297 fit_gen(lastgen , lg)
298
299 print("FIRST FIT GEN:", fg)
300 print("SECOND FIT GEN:", sg)
301 print("LAST FIT GEN:", lg)
302
303
304 #math fitness function
305 x = np.linspace(0,math.pi,200)
306 y = x + abs(np.sin(32*x))
307
308 #plot fitness function vs x and chromossomes vs fitness
309 fig , ax = plot.subplots()
310 ax.plot(x, y, color='blue', label = "fitness function")
311 ax.scatter(firstgen , fg, color='orange', label = "Chomossomes First Gen")
312 ax.scatter(secgen , sg, color='black', label = "Chomossomes Sec Gen")
313 ax.scatter(lastgen , lg, color='green', label = "Chomossomes Third Gen")
314
315 plot.legend()
316 plot.show()
317
318 #pause
319 os.system("pause")

```


2 Análise

2.a Aptidão média

Os gráficos de aptidão média, considerando $pm=0.001$ e $pc = 0.7$ são mostrados na figura 1:



(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 1: Gráfico da aptidão média para várias gerações.


Como mostrado na figura 1, com uma taxa de mutação baixa e uma taxa de cruzamento relativamente alta, tem-se que para populações menores, a aptidão média oscila nas primeiras 100 gerações e depois tende a crescer e estabilizar-se num valor de aptidão bem superior àquela das primeiras gerações. Para populações bem maiores, há um comportamento similar, mas há maior variabilidade no valor da aptidão média por um período bem maior de tempo (em gerações).

Isto mostra que, para populações maiores, o crescimento da aptidão média ao decorrer das gerações é mais devagar, provavelmente, por conta da maior variabilidade genética da população, fazendo com que diversos cromossomos de menor aptidão se cruzem mais vezes do que ocorre em pequenas populações.

Os gráficos de aptidão média, considerando $pm=0.001$ e $pc = 0.2$ são mostrados abaixo:



(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.


Figura 2: Gráfico da aptidão média para várias gerações.

Para uma taxa de cruzamento menor, nota-se que houve uma oscilação maior no valor de aptidão média nas primeiras 100 gerações da população de tamanho igual a 60. Enquanto que, para uma população três vezes maior, o valor médio da aptidão oscila ao decorrer de todas as gerações, mostrando que menos cruzamentos em uma população maior torna a busca por uma solução ótima mais vagarosa.

Na figura 3 são mostrados os gráficos de aptidão média, considerando $pm=0.001$ e $pc = 0.9$. Logo, pode-se concluir que, tanto para populações menores, quanto para populações maiores, o aumento na taxa de cruzamento causa maior inserção de novos cromossomos na população, os quais tendem a serem mais aptos que os de gerações anteriores. Além disso, a busca por um valor ótimo é mais rápida, convergindo para um valor de aptidão média maior do que a obtida com taxa de cruzamento menor.




(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 3: Gráfico da aptidão média para várias gerações.

Os gráficos de aptidão média, considerando $pm=0.01$ e $pc = 0.7$ são mostrados na figura 4:



(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 4: Gráfico da aptidão média para várias gerações.


O aumento da taxa de mutação causou, em uma população menor, oscilações significativas no valor da aptidão média, estabilizando em valor cuja diferença para as aptidões médias das primeiras gerações é menor do que o observado em situações anteriores. Já para uma população muito maior, este aumento na

taxa de mutação também ocasionou variações, mas o valor de aptidão média alcançado foi maior. Com isso, pode-se concluir que as mutações em populações maiores tendem a diversificar mais os cromossomos, cuja recombinação contínua ao decorrer das gerações causam um aumento na aptidão média da população, enquanto que em populações menores, há um fator de aleatoriedade mais decisivo que, portanto, pode levar a um comportamento mais caótico na aptidão média.

Os gráficos de aptidão média, considerando $pm=0.01$ e $pc = 0.2$ são mostrados na figura 5:



(a) População igual a 60 cromossomos.



(b) População igual a 180 cromossomos.

Figura 5: Gráfico da aptidão média para várias gerações.

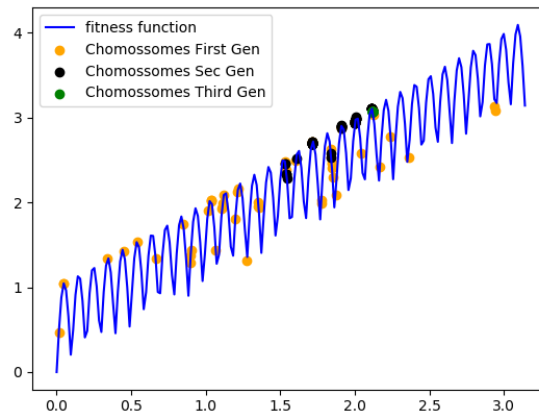
Finalmente, para uma menor taxa de cruzamento e maior taxa de mutação, tem-se que o comportamento é bastante parecido em populações maiores e menores. Isso indica que uma taxa de cruzamento baixa aliada a uma taxa de mutação alta, resultam em um comportamento bastante oscilatório no valor da aptidão média, haja vista que ser, por um lado, a mutação causa atrapalha a busca por uma solução ótima, apesar de evitar uma estagnação na aptidão média, por outro lado, a baixa taxa de cruzamento diminui a probabilidade de um cromossomo que foi modificado (mutante) ser re combinado com outro modificado.

2.b Aptidão em função do cromossomo

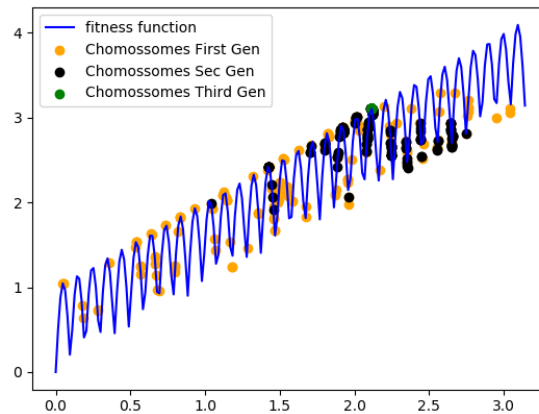
Finalmente, visando visualizar melhor o aumento da aptidão ao decorrer das gerações, foram plotados para cada situação descrita anteriormente os gráficos da aptidão em função dos cromossomos (para a primeira, décima e última geração) e também a função matemática do fitness.

Para a primeira situação, possível ver no caso da população menor mostrada na figura 6(a) que, logo na primeira geração de cromossomos, há um cromossomo com a maior aptidão de todas. Entretanto, os outros cromossomos da população inicial encontram-se bastante dispersos na parte baixa do gráfico de fitness, indicando portanto que a aptidão média será baixa. Para a décima geração, nota-se uma concentração maior dos cromossomos em um valor um pouco mais elevado de aptidão média, mas também disperso no gráfico. A última geração, entretanto, está toda concentrada num valor de aptidão maior, sem espalhamento da aptidão dos cromossomos, o que indica que a aptidão média da última geração é superior. Para uma população maior, o mesmo fenômeno ocorre, mudando apenas a maior variabilidade da primeira e décima gerações.

Observação: na legenda dos gráficos, considerar, respectivamente: a segunda geração como sendo a décima e a terceira é a última geração (última iteração do algoritmo genético).




(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 6: Gráfico da aptidão em função do cromossomo para diversas gerações para $p_m = 0.001$ e $p_c = 0.7$.

Para a segunda e demais situações, o mesmo fenômeno ocorre:

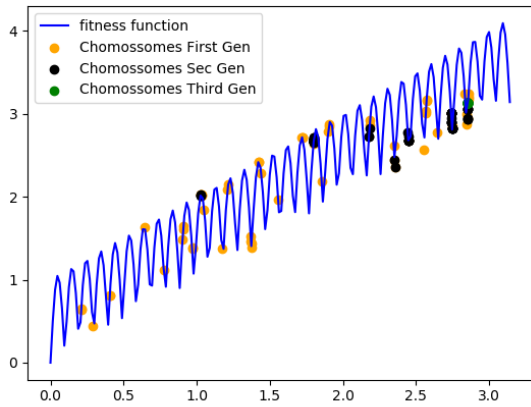


(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 7: Gráfico da aptidão em função do cromossomo para diversas gerações para $p_m = 0.001$ e $p_c = 0.2$.




(a) População igual a 60 cromossomos.




(b) População igual a 180 cromossomos.

Figura 8: Gráfico da aptidão em função do cromossomo para diversas gerações para $p_m = 0.001$ e $p_c = 0.9$.

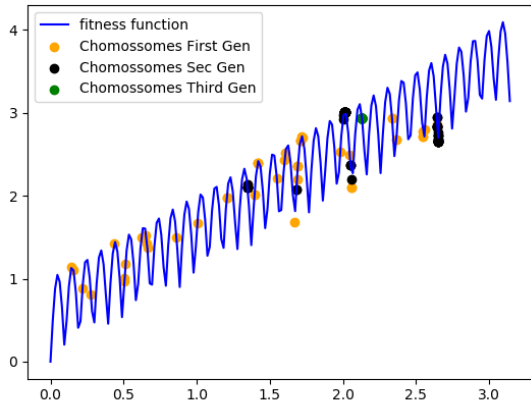


(a) População igual a 60 cromossomos.

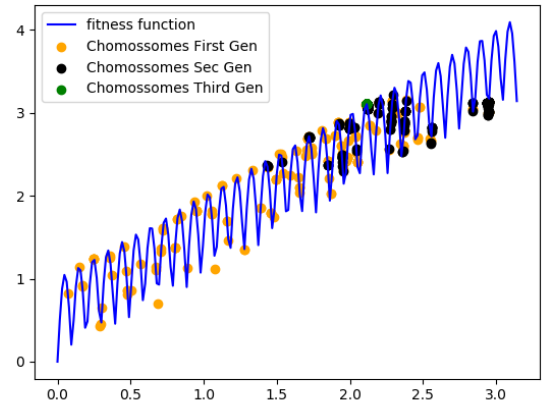


(b) População igual a 180 cromossomos.

Figura 9: Gráfico da aptidão em função do cromossomo para diversas gerações para $p_m = 0.01$ e $p_c = 0.7$.



(a) População igual a 60 cromossomos.



(b) População igual a 180 cromossomos.

Figura 10: Gráfico da aptidão em função do cromossomo para diversas gerações para $p_m = 0.01$ e $p_c = 0.2$.